Modelo de predicción de Churn de clientes en logística mediante Machine Learning y arquitectura escalable en AWS

Juan Pablo Saenz Perilla

6 de marzo de 2026

Índice

1. Introducción **2**

2. Objetivo **2**

3. Definición del problema de negocio **2**

4. Definición de la variable churn **2**

5. Descripción, limpieza y preparación de datos **2**

6. Análisis exploratorio de datos (EDA) **3**

7. Ingeniería de características **10**

8. Modelado predictivo y evaluación del modelo **11**

9. Predicción e inferencia **14**

10. Arquitectura de despliegue en AWS **16**
- 10.1. Diagrama y explicación . . . 16
- 10.2. Construcción en AWS . . . 17

11. Consideraciones **20**
- 11.1. Supuestos del modelo . . . 20
- 11.2. Riesgos del modelo . . . 20
- 11.3. Limitaciones del dataset . . . 20

12. Conclusiones **20**

13. Recomendaciones de negocio **21**

14. Trabajo futuro y mejoras del modelo **21**

1. Introducción

La retención de clientes es un factor clave para la sostenibilidad de empresas del sector logístico. La identificación temprana de clientes con riesgo de abandono permite diseñar estrategias de retención basadas en datos y optimizar la toma de decisiones. En este contexto, el presente trabajo desarrolla un modelo de predicción de churn utilizando técnicas de ciencia de datos y aprendizaje automático. El proceso abarca desde la limpieza y preparación de datos, análisis exploratorio, ingeniería de características y entrenamiento de modelos, hasta el diseño de una arquitectura escalable en AWS que permite operacionalizar la solución siguiendo buenas prácticas de MLOps.

2. Objetivo

Desarrollar e implementar un modelo de aprendizaje automático para predecir la probabilidad de abandono de clientes en un contexto logístico, utilizando información histórica de comportamiento, permitiendo anticipar riesgos de pérdida y apoyar la toma de decisiones basada en datos. Integrando procesos de limpieza de datos, ingeniería de características, evaluación comparativa de modelos y una arquitectura conceptual en AWS que permita su despliegue y uso en entornos productivos.

3. Definición del problema de negocio

La compañía tiene un dataset histórico de "Comportamiento de Clientes", pero los datos nunca han sido procesados formalmente. Están en un estado "crudo": hay valores nulos, formatos de fecha inconsistentes y variables que no deberían usarse por privacidad.

El abandono de clientes representa una pérdida directa de ingresos para la empresa. Identificar de forma temprana a los clientes con alta probabilidad de churn permite implementar estrategias de retención, optimizar campañas de marketing y priorizar acciones comerciales.

4. Definición de la variable churn

La variable objetivo del modelo corresponde a *churn_label*, una variable binaria donde:

- 1 indica que el cliente ha abandonado el servicio.
- 0 indica que el cliente permanece activo.

5. Descripción, limpieza y preparación de datos

El proceso de limpieza de datos se diseñó con el objetivo de mejorar la calidad, consistencia y confiabilidad de la información antes del análisis y modelado predictivo. En primer lugar, se realizó la detección automática del delimitador del archivo mediante la herramienta *Sniffer* de la librería *csv*, lo cual permitió garantizar una lectura correcta del conjunto de datos independientemente del formato utilizado en el archivo original.

Posteriormente, se implementó un procedimiento para estandarizar los valores nulos, reemplazando múltiples representaciones comunes de datos faltantes (como "null", "NA", "n/a", cadenas vacías o espacios) por el valor estándar *NaN*. Este paso es fundamental para asegurar que las funciones de análisis y tratamiento de datos puedan identificar correctamente las observaciones incompletas.

En relación con las variables temporales, se identificó la presencia de múltiples formatos de fecha. Para resolver esta inconsistencia se desarrolló una función que analiza los componentes de cada fecha, detecta el año, el mes y el día independientemente del separador utilizado, y posteriormente normaliza todas las fechas al formato estándar *YYYY-MM-DD*. Esto permite garantizar coherencia temporal en variables críticas como *signup_date* y *last_purchase_date*.

Asimismo, se realizó un análisis de duplicados basado en el identificador único del cliente (*customer_id*). Primero se eliminaron registros completamente duplicados y posteriormente, en los casos donde existían múltiples registros para un mismo cliente, se conservó la observación con mayor cantidad de información válida (es decir, con menor número de valores faltantes). Este procedimiento permite preservar la información más completa disponible para cada cliente.

En cuanto al tratamiento de valores faltantes en variables numéricas, se asumió que valores nulos en *total_shipments* y *monthly_spend* corresponden a ausencia de actividad, por lo que fueron imputados con cero. Por otro lado, las observaciones con valores faltantes en *churn_label* fueron eliminadas, dado que esta variable corresponde al objetivo del modelo y su ausencia impediría el entrenamiento de los algoritmos de clasificación.

Finalmente, se realizó la conversión de tipos de datos para garantizar consistencia en las variables: *monthly_spend* se transformó a tipo numérico decimal, mientras que *total_shipments* y *churn_label* se convirtieron a variables enteras.

Para el tratamiento de valores atípicos en las variables numéricas se aplicaron dos estrategias. En primer lugar, los valores negativos en la variable *monthly_spend* fueron truncados a cero utilizando la función *clip*, ya que un gasto negativo no tiene interpretación económica en el contexto del problema y probablemente corresponde a errores de registro.

Posteriormente, se aplicó una técnica de *winsorización* basada en el rango intercuartílico (IQR) para las variables *monthly_spend* y *total_shipments*. Este método calcula los límites inferior y superior utilizando los cuartiles de la distribución y restringe los valores extremos al rango esperado de los datos. De esta manera, se reduce el impacto de outliers sin eliminar observaciones, lo que permite preservar la información del dataset y mejorar la estabilidad de los modelos de aprendizaje automático.

Adicionalmente, durante el proceso de preparación de datos se mantuvo el anonimato de variables sensibles relacionadas con la identificación de los clientes, tales como el nombre completo, correo electrónico, número telefónico y dirección. Estas variables no fueron utilizadas en el modelado con el fin de proteger la privacidad de los usuarios y evitar posibles riesgos asociados al tratamiento de información personal.

En conjunto, estas etapas de limpieza y estandarización permiten reducir errores, inconsistencias y sesgos en los datos, mejorando así la calidad de la información utilizada en el análisis exploratorio y en el desarrollo de modelos predictivos de churn.

6. Análisis exploratorio de datos (EDA)

La distribución del gasto mensual presenta una moderada asimetría hacia la derecha, con la mayoría de los clientes concentrados en niveles de gasto relativamente bajos y un pequeño grupo con valores elevados. Al comparar entre clientes que abandonaron el servicio y aquellos que permanecen activos, se observa que los niveles de gasto más bajos tienden a asociarse con mayores tasas de churn, lo que sugiere que el nivel de actividad económica del cliente puede ser un predictor relevante de la probabilidad de abandono.

signup_date	last_purchase_date	monthly_spend	total_shipments	churn_label
2023-01-15	2025-12-05	450.5	12	0
2023-02-20	2025-05-10	1200.0	45	0
2023-03-05	2025-03-25	3435.0	8	1
2023-04-12	2025-06-01	890.2	22	0
2023-05-30	2024-12-20	310.0	5	1

La evolución temporal de *signup_date* muestra una incorporación de clientes relativamente estable a lo largo del periodo analizado, con ligeros incrementos hacia finales de 2023 y durante 2024. Esta

variable es relevante para el modelado de churn, ya que permite derivar métricas como la antigüedad del cliente (*tenure*) o cohortes de adquisición, las cuales pueden capturar diferencias en el comportamiento y riesgo de abandono.

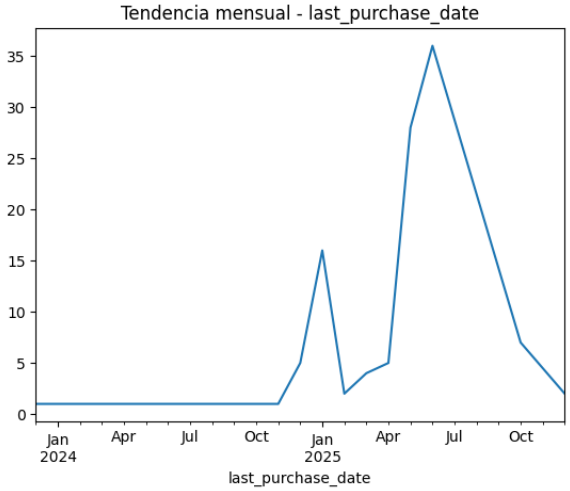

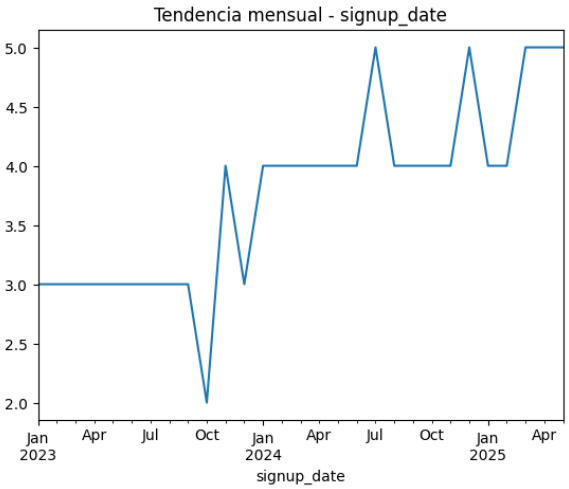

La evolución mensual de *last_purchase_date* muestra una actividad relativamente estable durante 2024 y un incremento en el número de transacciones hacia finales de ese año y durante 2025. Esta variable es clave para el análisis de churn, ya que permite construir la métrica de recencia (*recency*), donde mayores periodos sin compras suelen asociarse con una mayor probabilidad de abandono.

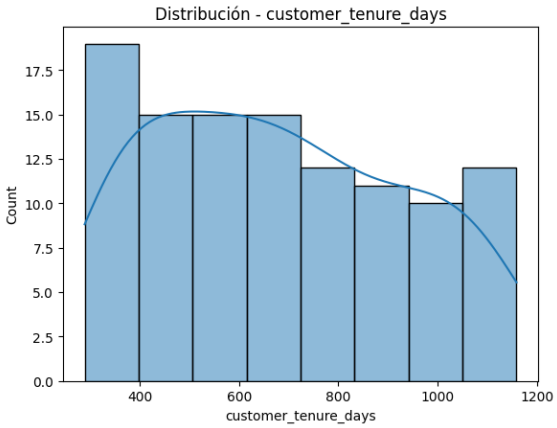

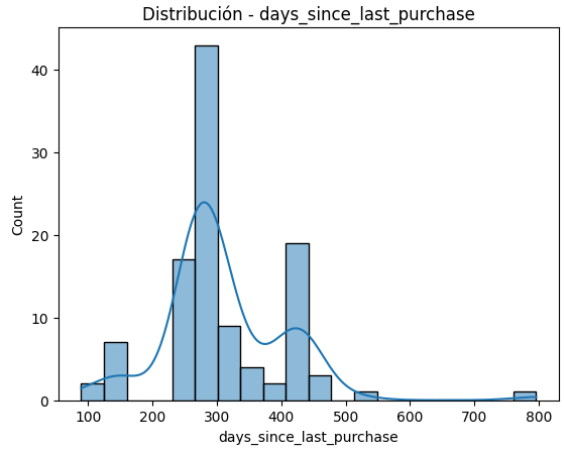

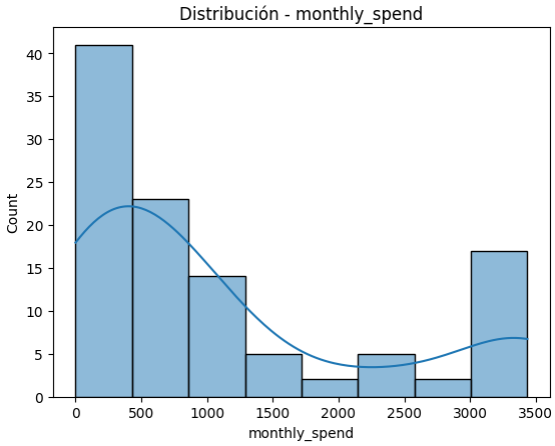

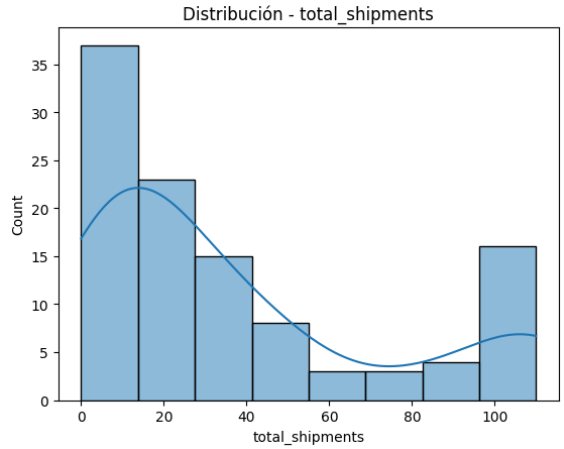

feature	count	mean	std	min	25 %	50 %	75 %	max	skew	kurtosis
monthly_spend	109	1106.8	1184.3	0.0	210.0	615.0	1500.0	3435.0	1.1	-0.3
total_shipments	109	37.0	36.9	0.0	10.0	22.0	50.0	110.0	1.0	-0.3
customer_tenure_days	109	680.0	252.7	289.0	459.0	654.0	886.0	1159.0	0.2	-1.1
days_since_last_purchase	108	310.1	95.0	89.0	266.0	285.5	351.2	796.0	1.2	5.6

Las variables numéricas presentan distribuciones levemente asimétricas, especialmente en *monthly_spend* y *total_shipments*, donde algunos clientes concentran niveles de gasto o actividad superiores al resto. En contraste, *customer_tenure_days* muestra una distribución más equilibrada, mientras que *days_since_last_purchase* presenta una asimetría moderada asociada a periodos de inactividad más prolongados.

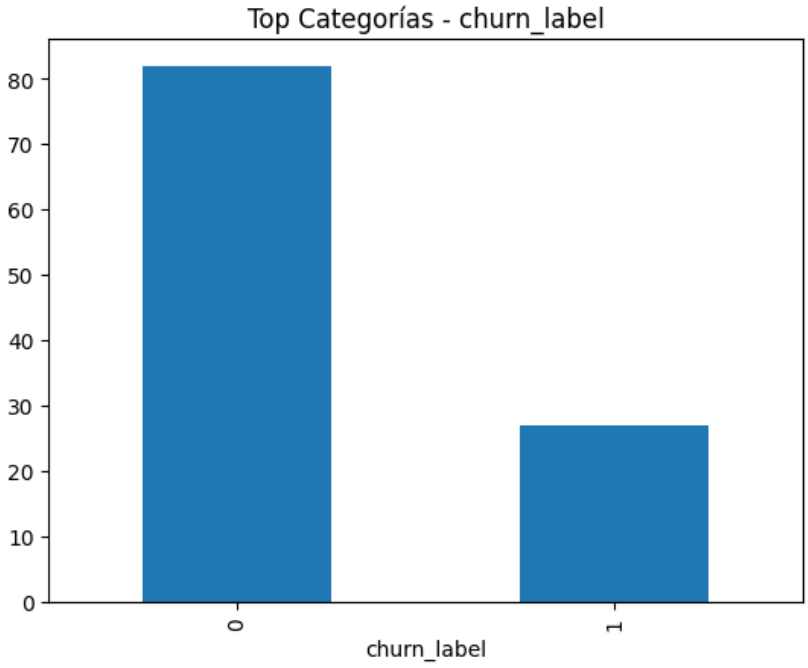

La variable objetivo *churn_label* presenta un desbalance moderado entre clases, con aproximadamente 75 % de clientes activos y 25 % que han abandonado el servicio. Aunque este desbalance no es extremo, debe considerarse durante el modelado mediante técnicas como ponderación de clases o el uso de métricas de evaluación robustas para evitar sesgos hacia la clase mayoritaria.

churn	count	mean	std	min	25 %	50 %	75 %	max	feature
0	82	1378	1198	0	505	900	2425	3435	monthly_spend
1	27	282	646	0	0	150	310	3435	monthly_spend
0	82	48	37	0	18	34	80	110	total_shipments
1	27	5	4	0	2	5	8	15	total_shipments
0	82	650	242	289	456	626	832	1145	customer_tenure_days
1	27	771	267	308	564	790	988	1159	customer_tenure_days
0	82	280	70	89	263	277	294	424	days_since_last_purchase
1	26	404	103	268	345	419	437	796	days_since_last_purchase

El análisis descriptivo por *churn_label* muestra que *monthly_spend* presenta diferencias claras entre clientes activos y aquellos que abandonan, evidenciando que los clientes que permanecen en la plataforma tienden a registrar niveles de gasto más altos. En contraste, *total_shipments* y *days_since_last_purchase* también muestran diferencias entre ambos grupos, indicando que una menor frecuencia de uso del servicio y mayores periodos de inactividad están asociados con un mayor riesgo de churn. Asimismo, *customer_tenure_days* sugiere que algunos clientes con mayor antigüedad pueden eventualmente pre-

sentar mayor probabilidad de abandono.

signup_month	churn_label
2023-01	0.67
2023-02	0.33
2023-03	0.33
2023-04	0.00
2023-05	0.67
2023-06	0.33
2023-07	1.00
2023-08	0.33
2023-09	0.33
2023-10	0.00
2023-11	0.00
2023-12	0.33
2024-01	0.25
2024-02	0.00
2024-03	0.00
2024-04	0.75
2024-05	0.00
2024-06	0.25
2024-07	0.20
2024-08	0.25
2024-09	0.50
2024-10	0.00
2024-11	0.25
2024-12	0.20
2025-01	0.00
2025-02	0.25
2025-03	0.00
2025-04	0.00
2025-05	0.40

El análisis de churn por cohorte de registro muestra mayor variabilidad en las cohortes tempranas de 2023, con algunos meses presentando tasas de abandono elevadas. En contraste, las cohortes de 2024 y 2025 exhiben mayor estabilidad en las tasas de churn. Este análisis sugiere que el momento de adquisición y la antigüedad del cliente pueden ser factores relevantes para explicar el riesgo de abandono.

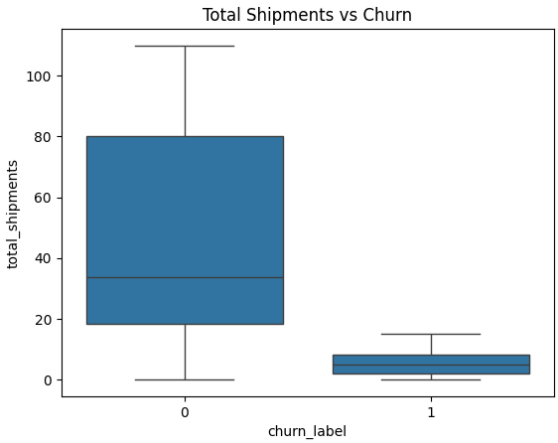

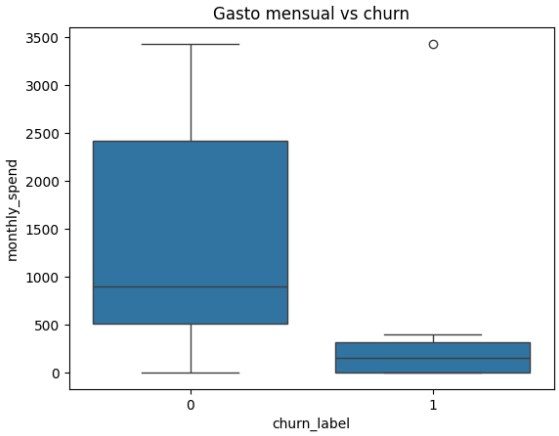

El análisis comparativo muestra que los clientes activos presentan, en promedio, mayores niveles

de gasto (*monthly_spend*) y un mayor número de envíos (*total_shipments*) que aquellos que abandonan el servicio. En contraste, los clientes con churn exhiben niveles de actividad más bajos y concentrados. Estos resultados sugieren que una menor intensidad de uso del servicio está asociada con un mayor riesgo de abandono.

month	churn_label	monthly_spend	total_shipments
2023-12-01	1	100.0	2.0
2024-10-01	1	200.0	2.0
2024-11-01	1	210.0	5.0
2024-12-01	1	182.0	4.8
2025-01-01	0	1442.9	50.3
2025-01-01	1	71.4	4.0
2025-02-01	1	370.0	9.0
2025-03-01	0	1500.0	60.0
2025-03-01	1	1248.3	9.7
2025-04-01	0	700.0	5.5
2025-04-01	1	10.0	1.0
2025-05-01	0	1107.2	39.8
2025-05-01	1	146.7	3.3
2025-06-01	0	1648.4	56.0
2025-06-01	1	300.0	6.5
2025-10-01	0	1652.9	62.4
2025-12-01	0	225.3	16.0

El análisis agregado por mes muestra que los clientes activos presentan, en promedio, mayores niveles de gasto (*monthly_spend*) y número de envíos (*total_shipments*) en comparación con aquellos que presentan churn. En contraste, los clientes que abandonan el servicio exhiben niveles de actividad más bajos y estables. Estos resultados sugieren que una menor intensidad de uso del servicio puede constituir una señal temprana de abandono.

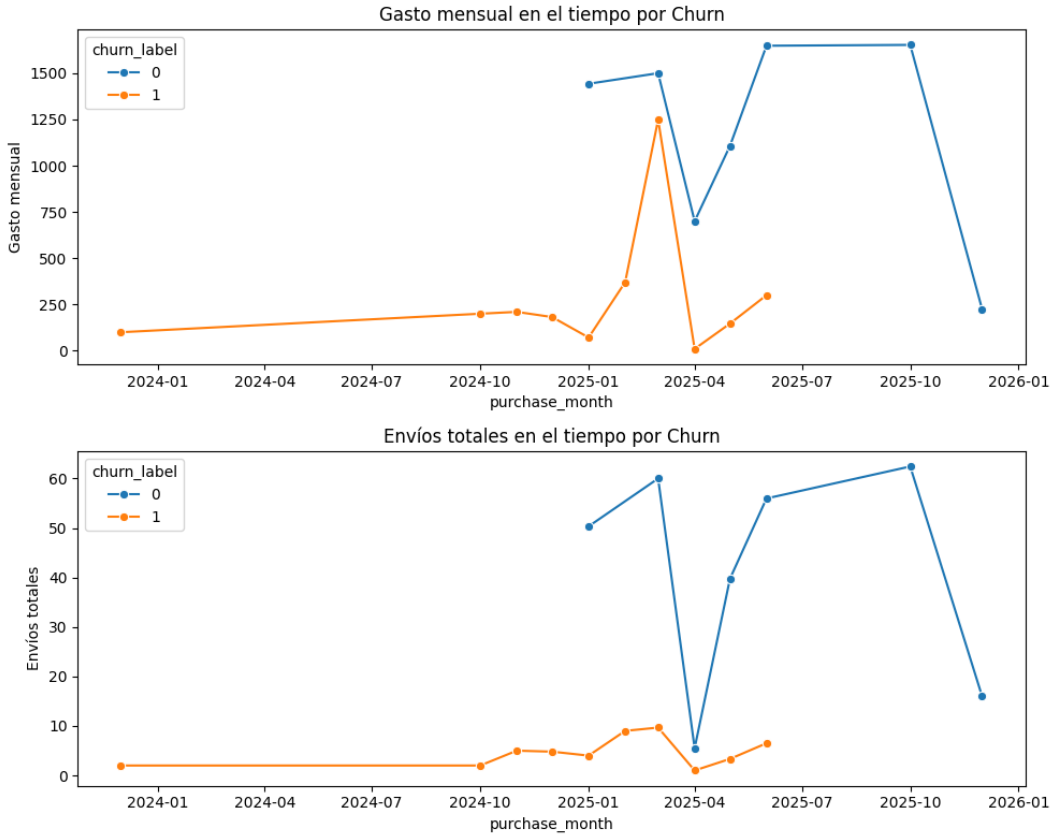

El análisis temporal muestra que los clientes activos presentan, en promedio, mayores niveles de gasto y número de envíos a lo largo del tiempo, así como mayor variabilidad en estas métricas. En contraste, los clientes que presentan churn tienden a mostrar niveles de actividad considerablemente menores. En conjunto, estos resultados sugieren que la intensidad de uso del servicio, medida a través del gasto y la frecuencia de envíos, está estrechamente relacionada con la retención de clientes.

index	customer_id	feature	value
0	C001	days_since_last_purchase	90.0
54	C056	days_since_last_purchase	516.0
80	C082	days_since_last_purchase	796.0
96	C098	days_since_last_purchase	89.0

El análisis de outliers mediante el método IQR identificó valores atípicos en la variable *days_since_last_purchase*, con algunos registros que alcanzan valores superiores al comportamiento típico de la base. Para las etapas posteriores del análisis —incluyendo la ingeniería de características, el entrenamiento de modelos y la fase de predicción— estos valores atípicos fueron tratados utilizando la misma metodología de winsorización basada en IQR descrita previamente, con el fin de reducir el impacto de observaciones extremas y mejorar la estabilidad del proceso de modelado.

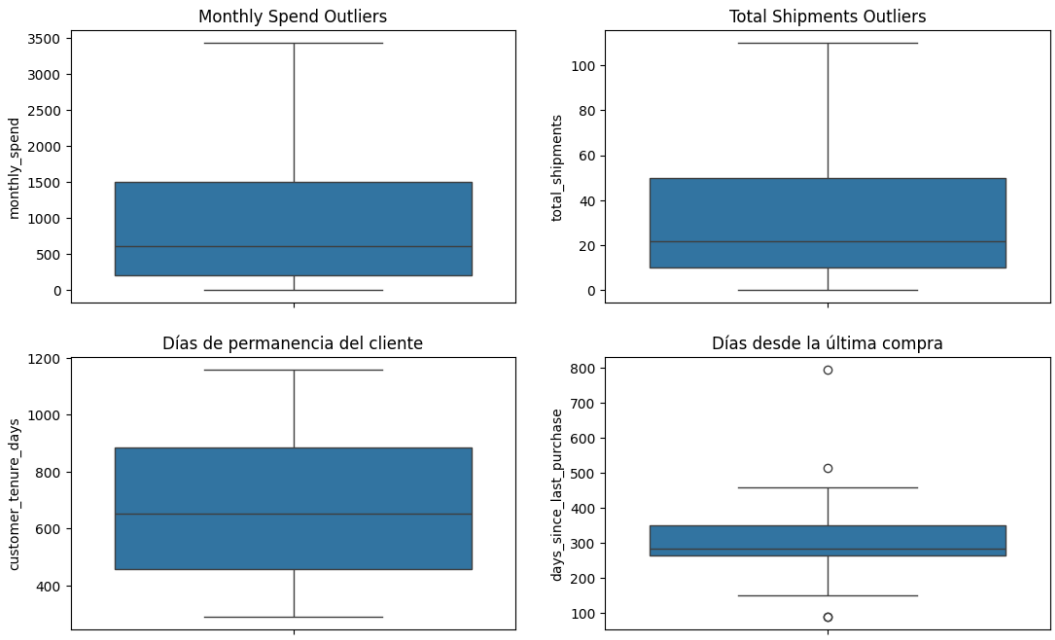

Los diagramas de caja evidencian la presencia de valores atípicos principalmente en *days_since_last_purchase*, con distribuciones sesgadas y algunos valores altos. En contraste, *customer_tenure_days* presenta una distribución más estable sin outliers relevantes, mientras que *monthly_spend* y *total_shipments* muestra alguna elvación pero con una concentración principal en rangos moderados. A partir de acá, los outliers para *days_since_last_purchase* ya están tratados con la metodología de winsorización basara en IQR.

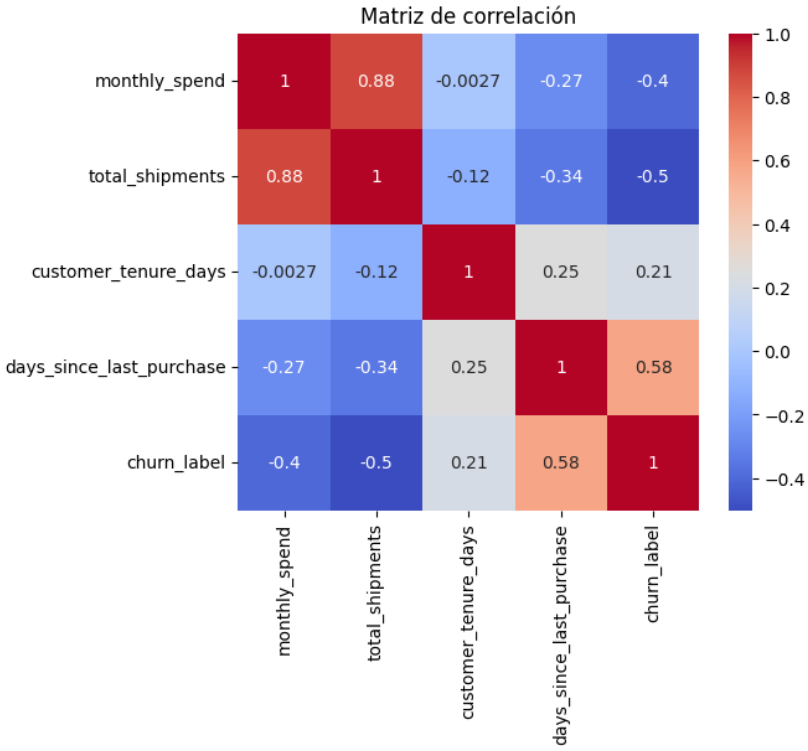

La matriz de correlación muestra niveles moderados de asociación entre algunas variables explicativas. La relación más fuerte con el churn corresponde a *days_since_last_purchase* ($r = 0{,}58$), indicando que mayores periodos de inactividad aumentan la probabilidad de abandono. Asimismo, *total_shipments* presenta una correlación negativa moderada ($r = -0{,}50$), lo que sugiere que una mayor

frecuencia de uso reduce el churn. En contraste, *customer_tenure_days* muestra una relación positiva débil ($r = 0{,}21$), mientras que *monthly_spend* presenta una correlación negativa moderada con la variable objetivo ($r = -0{,}40$), indicando que mayores niveles de gasto tienden a estar asociados con una menor probabilidad de abandono.

feature	correlation	p_value	n
monthly_spend	-0.40	0.00	109
total_shipments	-0.50	0.00	109
customer_tenure_days	0.21	0.03	109
days_since_last_purchase	0.58	0.00	108

Se estimó la correlación punto-biserial entre las variables numéricas y *churn_label*. La variable con mayor relación fue *days_since_last_purchase* ($r = 0{,}58$, $p < 0{,}001$), indicando que mayores periodos de inactividad aumentan la probabilidad de abandono. Por su parte, *total_shipments* mostró una correlación negativa moderada ($r = -0{,}50$, $p < 0{,}001$), sugiriendo que un mayor uso del servicio reduce el churn. *customer_tenure_days* presentó una relación positiva débil ($r = 0{,}21$, $p < 0{,}05$), mientras que *monthly_spend* evidenció una correlación negativa moderada ($r = -0{,}40$, $p < 0{,}001$), indicando que mayores niveles de gasto están asociados con una menor probabilidad de abandono.

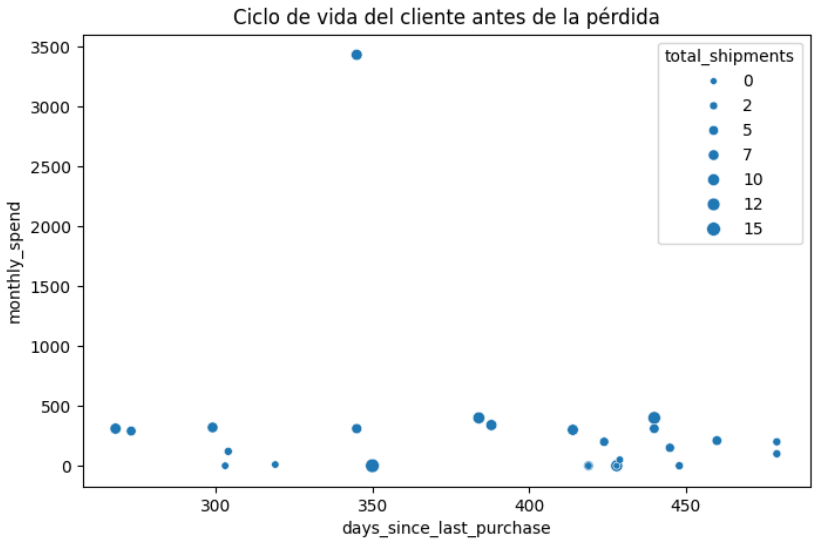

El análisis del ciclo de vida de los clientes que presentan churn muestra que la mayoría se concentra en valores relativamente elevados de *days_since_last_purchase*, lo que indica periodos prolongados de inactividad antes del abandono. Adicionalmente, estos clientes tienden a presentar niveles de gasto relativamente bajos y un número reducido de envíos, lo que sugiere una menor intensidad de uso del servicio. En conjunto, estos resultados refuerzan la importancia de las variables de recencia y frecuencia como indicadores relevantes del riesgo de churn.

7. Ingeniería de características

Se realizó un proceso de *feature engineering* para capturar dimensiones clave del comportamiento del cliente. En primer lugar, los valores faltantes de *last_purchase_date* fueron imputados con *signup_date*, asumiendo que la última interacción coincide con la fecha de registro. Posteriormente, se generaron variables derivadas como *customer_tenure_days* (antigüedad del cliente), *days_since_last_purchase* (recencia), *shipments_per_month* (frecuencia de uso) y *spend_per_shipment* (intensidad de gasto). Estas variables permiten capturar dimensiones de comportamiento asociadas a recencia, frecuencia y valor del cliente, comúnmente utilizadas en modelos de predicción de churn.

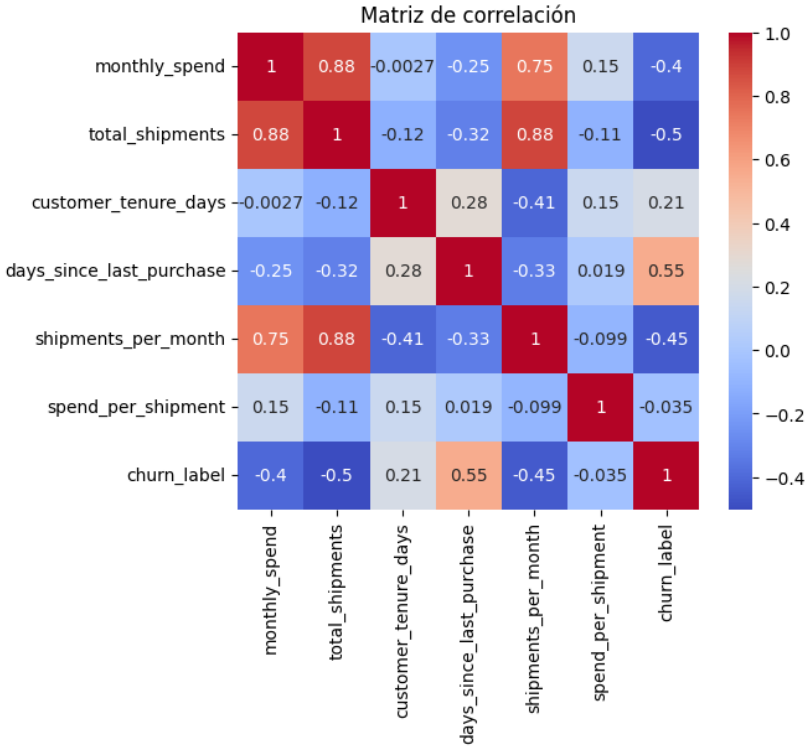

La matriz de correlación con las variables derivadas muestra que *days_since_last_purchase* mantiene la relación positiva más fuerte con el churn ($r = 0{,}55$), indicando que mayores periodos de inactividad aumentan la probabilidad de abandono. Asimismo, *shipments_per_month* presenta una correlación negativa moderada ($r = -0{,}45$), sugiriendo que una mayor frecuencia de uso reduce el riesgo de churn. Finalmente, se observa una alta correlación entre *total_shipments* y *shipments_per_month* ($r = 0{,}88$), lo que refleja que ambas variables capturan información similar sobre la intensidad de uso del servicio.

Finalmente, se seleccionó el conjunto de variables relevantes para el modelado, incluyendo la variable objetivo *churn_label* y las variables explicativas relacionadas con gasto, frecuencia de uso y comportamiento temporal del cliente: *monthly_spend*, *total_shipments*, *customer_tenure_days*, *days_since_last_purchase*, *shipments_per_month* y *spend_per_shipment*. Esta selección busca capturar distintas dimensiones del comportamiento del cliente relevantes para la predicción del churn.

8. Modelado predictivo y evaluación del modelo

Para el modelado se definieron como variables predictoras *monthly_spend*, *total_shipments*, *customer_tenure_days*, *days_since_last_purchase*, *shipments_per_month* y *spend_per_shipment*, mientras que *churn_label* se utilizó como variable objetivo. El conjunto de datos se dividió en entrenamiento y prueba (70 %-30 %) mediante muestreo estratificado para preservar la proporción de clases. Posteriormente, las variables numéricas fueron estandarizadas utilizando *StandardScaler*. Finalmente, se aplicó la técnica *SMOTE* sobre el conjunto de entrenamiento para reducir el desbalance de clases, generando ejemplos sintéticos de la clase minoritaria hasta alcanzar el 50 % del tamaño de la clase mayoritaria.

Con el objetivo de comparar distintos enfoques de modelado, se entrenaron varios algoritmos de clasificación utilizando validación cruzada estratificada de 5 particiones (*Stratified K-Fold*), lo que permite preservar la proporción de clases en cada partición y obtener estimaciones más robustas del desempeño. Para cada modelo se realizó un proceso de optimización de hiperparámetros mediante *Grid Search*, utilizando el área bajo la curva ROC (*ROC-AUC*) como métrica de evaluación.

Se evaluaron tanto modelos lineales como no lineales, incluyendo *Logistic Regression*, *Random Forest*, *Gradient Boosting*, *XGBoost* y *Support Vector Machines*. Los espacios de búsqueda incluyeron

parámetros clave como la regularización en regresión logística, el número de árboles y profundidad en modelos de ensamble, así como parámetros de aprendizaje y muestreo en algoritmos de boosting. Este enfoque permitió identificar las configuraciones óptimas de cada modelo y comparar su capacidad predictiva en la identificación de clientes con riesgo de churn.

Adicionalmente, se evaluaron modelos basados en redes neuronales para capturar posibles relaciones no lineales en los datos. En primer lugar, se entrenó un *Multilayer Perceptron* (MLPClassifier) optimizando sus hiperparámetros mediante *Grid Search* con validación cruzada estratificada y utilizando *ROC-AUC* como métrica de evaluación.

Posteriormente, se implementó una red neuronal profunda utilizando *TensorFlow/Keras*, compuesta por dos capas densas con activación ReLU, normalización por lotes (*Batch Normalization*) y regularización mediante *Dropout* para reducir el riesgo de sobreajuste. La optimización de hiperparámetros se realizó mediante *Optuna*, explorando configuraciones de tamaño de capas ocultas, tasa de aprendizaje, proporción de *dropout* y tamaño de lote. El entrenamiento incluyó *Early Stopping* basado en la pérdida de validación para mejorar la generalización del modelo y evitar sobreajuste.

Model	Score
NeuralNet	0.988
nn_tf_model	0.985
Logistic	0.984
RandomForest	0.984
XGBoost	0.981
SVM	0.974
GradientBoosting	0.971

La comparación de modelos se realizó utilizando la métrica *ROC-AUC* obtenida mediante validación cruzada. Los resultados muestran que las redes neuronales presentan el mejor desempeño, destacándose *NeuralNet* (0.988) y el modelo profundo implementado con *TensorFlow* (0.985). Los modelos *Logistic Regression* y *Random Forest* también presentan un desempeño competitivo, ambos con valores cercanos a 0.984. Por su parte, *XGBoost* y *SVM* muestran resultados ligeramente inferiores pero aún robustos, con valores alrededor de 0.98 y 0.97 respectivamente, mientras que *Gradient Boosting* registra el menor desempeño relativo (0.971). En conjunto, estos resultados indican que distintos enfoques de modelado logran un alto poder predictivo para la estimación del churn en este conjunto de datos.

Model	Accuracy	Precision	Recall	F1	ROC_AUC
RandomForest	0.939	1.000	0.750	0.857	1.000
XGBoost	0.879	1.000	0.500	0.667	1.000
Logistic	0.970	1.000	0.875	0.933	0.985
nn_tf_model	0.879	0.833	0.625	0.714	0.985
SVM	0.848	0.800	0.500	0.615	0.940
NeuralNet	0.909	0.857	0.750	0.800	0.915
GradientBoosting	0.909	1.000	0.625	0.769	0.890

La evaluación de los modelos sobre el conjunto de prueba muestra que *Random Forest* y *XGBoost* presentan el mejor desempeño en términos de *ROC-AUC* (1.00), indicando una alta capacidad de discriminación entre clientes que abandonan y aquellos que permanecen activos. En particular, *Random Forest* alcanza además una alta exactitud (0.94) y un equilibrio adecuado entre precisión y recall. Modelos como *Logistic Regression* y la red neuronal implementada con *TensorFlow* también muestran un desempeño competitivo, con valores de *ROC-AUC* cercanos a 0.99. Por su parte, *NeuralNet* y *Gradient Boosting* presentan resultados intermedios, mientras que *SVM* muestra el menor desempeño relativo. En conjunto, estos resultados confirman la efectividad de los modelos de ensamble para la predicción del churn en este conjunto de datos.

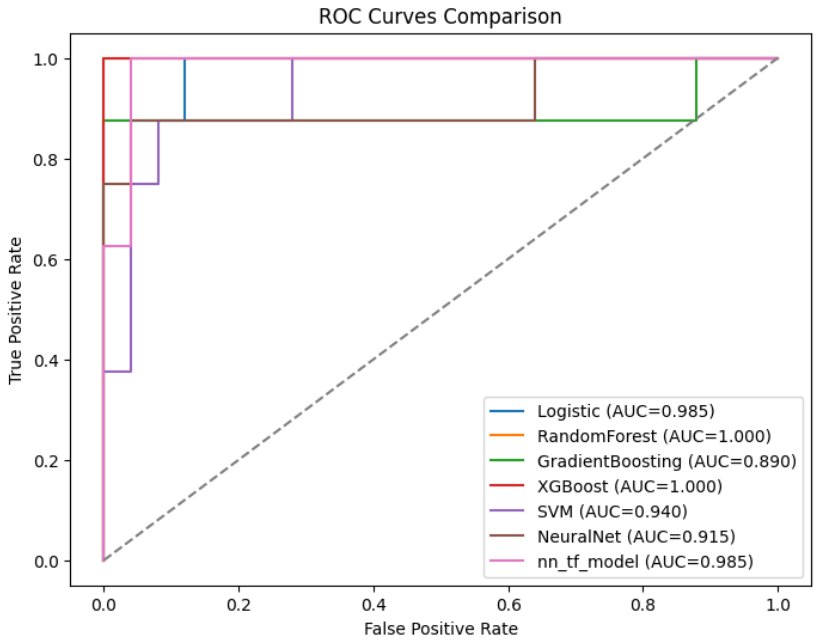

La comparación de las curvas ROC confirma el alto desempeño de los modelos evaluados, particularmente *Random Forest* y *XGBoost*, los cuales alcanzan un *AUC* cercano a 1.00, indicando una excelente capacidad de discriminación entre clientes que abandonan y aquellos que permanecen activos. Modelos como *Logistic Regression* y la red neuronal *MLP* también muestran un desempeño sólido, con valores de AUC muy cercanos a los mejores modelos. Por su parte, *Gradient Boosting* y *SVM* presentan resultados ligeramente inferiores, mientras que la red neuronal implementada en *TensorFlow* mantiene un desempeño competitivo. En conjunto, los resultados evidencian que distintos enfoques de modelado logran una alta capacidad predictiva para la estimación del churn en este conjunto de datos.

Model	TN	FP	FN	TP
Logistic	25	0	1	7
RandomForest	25	0	2	6
GradientBoosting	25	0	3	5
XGBoost	25	0	4	4
SVM	24	1	4	4
NeuralNet	24	1	2	6
nn_tf_model	24	1	3	5

El análisis de las matrices de confusión muestra que varios modelos logran identificar correctamente la totalidad de los clientes activos sin generar falsos positivos, entre ellos *Logistic Regression*, *Random Forest*, *Gradient Boosting* y *XGBoost*. Asimismo, *Random Forest* y *NeuralNet* presentan el mejor equilibrio en la detección de churn, identificando correctamente 6 de los 8 casos de abandono. En contraste, modelos como *Gradient Boosting*, *XGBoost* y *SVM* muestran un mayor número de falsos negativos, lo que indica una menor capacidad relativa para detectar clientes en riesgo de churn.

Feature	Importance
total_shipments	0.295
shipments_per_month	0.247
monthly_spend	0.235
days_since_last_purchase	0.145
spend_per_shipment	0.045
customer_tenure_days	0.034

El análisis de importancia de variables del modelo seleccionado indica que las características relacionadas con la frecuencia de uso del servicio son las más relevantes para la predicción del churn. En particular, *total_shipments* y *shipments_per_month* presentan la mayor contribución al modelo, seguidas por *monthly_spend*. Por su parte, *days_since_last_purchase* también muestra una influencia relevante, mientras que *spend_per_shipment* y *customer_tenure_days* presentan un impacto menor en la capacidad predictiva del modelo.

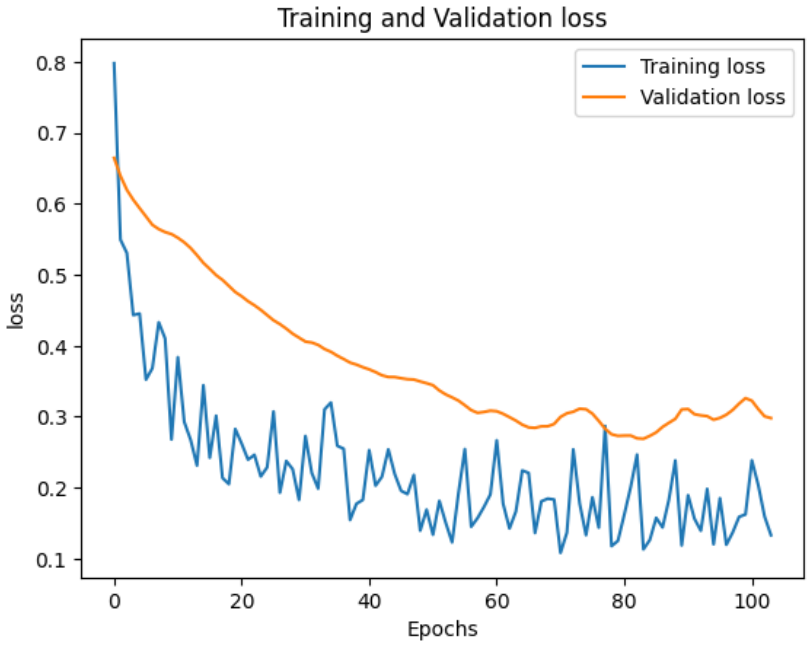

La evolución de la función de pérdida muestra una reducción rápida de la pérdida de entrenamiento durante las primeras épocas, seguida de una estabilización progresiva en valores bajos. La pérdida de validación también disminuye de manera sostenida en las etapas iniciales del entrenamiento, aunque posteriormente se observa una ligera divergencia respecto a la pérdida de entrenamiento, lo que sugiere la presencia de un leve sobreajuste. No obstante, el uso de *Early Stopping*, *Dropout* y *Batch Normalization* contribuye a mitigar este efecto y favorecer una mejor capacidad de generalización del modelo.

Finalmente, se implementó una función para identificar y almacenar automáticamente el mejor modelo entrenado. El procedimiento evalúa los modelos contenidos en un diccionario, compara sus puntajes de validación (*best_score_*) y selecciona aquel con el mayor desempeño. Posteriormente, el modelo óptimo se guarda en disco utilizando el formato correspondiente según su tipo: archivos *.joblib* para modelos basados en *scikit-learn* o *XGBoost*, y formato *.keras* para redes neuronales implementadas en *TensorFlow*. Este enfoque permite estandarizar el proceso de persistencia del modelo y facilita su posterior uso en etapas de despliegue o inferencia.

9. Predicción e inferencia

Para la etapa de inferencia se desarrolló una función que permite cargar automáticamente el modelo previamente guardado y generar predicciones de churn sobre nuevos datos. La función identifica el archivo del modelo dentro de una carpeta específica y lo carga según su formato, soportando tanto modelos almacenados en *joblib* (utilizados por *scikit-learn* y *XGBoost*) como redes neuronales guardadas en formatos *.keras* o *.h5*.

Una vez cargado el modelo, se calculan las probabilidades de abandono para cada observación y posteriormente se transforman en predicciones binarias utilizando un umbral de clasificación configurable. Este enfoque permite estandarizar el proceso de predicción, facilitando la reutilización del modelo

en entornos de producción o en nuevos conjuntos de datos sin necesidad de reentrenamiento.

Class	Precision	Recall	F1-score	Support
0	0.96	0.92	0.94	25
1	0.78	0.88	0.82	8
Accuracy		0.91		33
Macro avg	0.87	0.90	0.88	33
Weighted avg	0.91	0.91	0.91	33

ROC_AUC: 0.89

Como ejemplo de uso del modelo entrenado, se aplicó la función de predicción sobre un conjunto de datos y se evaluó su desempeño mediante métricas de clasificación. Los resultados muestran una exactitud cercana al 91 %, lo que indica una buena capacidad del modelo para clasificar correctamente a los clientes. En particular, el modelo presenta un *recall* elevado para la clase de churn (0.88), lo cual es especialmente relevante en problemas de retención, ya que permite detectar una proporción importante de clientes que podrían abandonar el servicio. Asimismo, las métricas de *precision* y *F1-score* evidencian un desempeño equilibrado entre ambas clases.

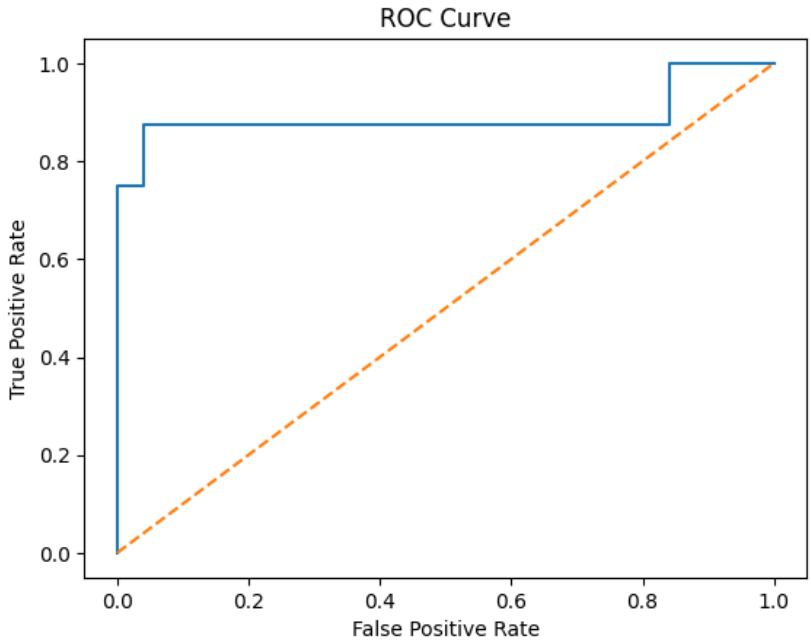

La curva ROC obtenida a partir de las predicciones del modelo muestra un desempeño satisfactorio en la capacidad de discriminación entre clientes que abandonan y aquellos que permanecen activos. La curva se ubica claramente por encima de la línea diagonal correspondiente a un clasificador aleatorio, lo que confirma que el modelo posee poder predictivo. En particular, el valor de *ROC-AUC* cercano a 0.90 indica un buen equilibrio entre sensibilidad y especificidad, permitiendo identificar correctamente una alta proporción de clientes con riesgo de churn.

Una vez entrenado el modelo, se implementó una función de predicción que permite cargar automáticamente el modelo guardado y generar inferencias sobre nuevos datos de clientes, devolviendo tanto la probabilidad de churn como la clasificación final. Este componente encapsula la lógica de inferencia y facilita su reutilización en entornos productivos. A partir de este punto, la función puede integrarse fácilmente en una arquitectura en la nube, como la propuesta en AWS, donde el modelo puede desplegarse mediante servicios como SageMaker para realizar predicciones en tiempo real o por lotes.

10. Arquitectura de despliegue en AWS

10.1. Diagrama y explicación

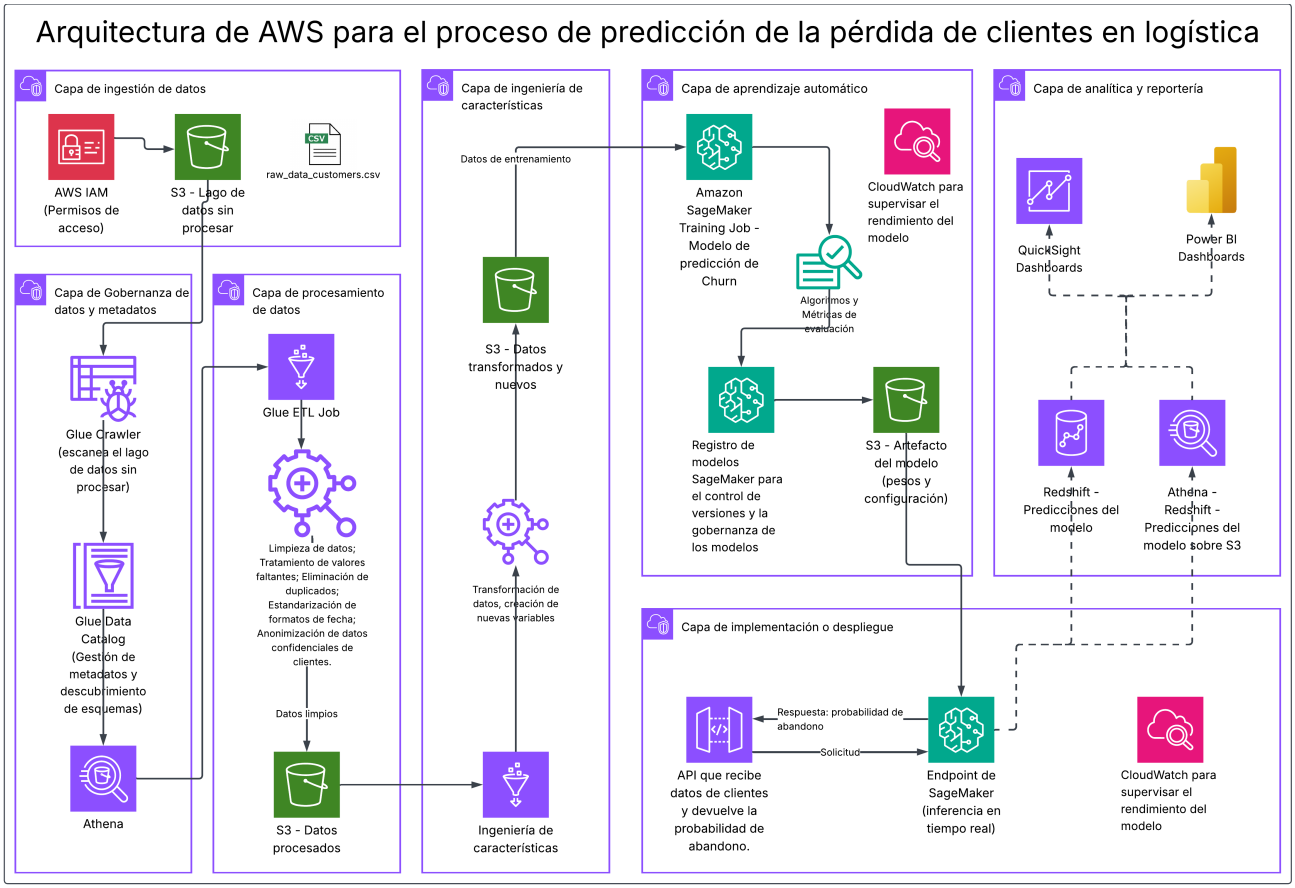

La arquitectura propuesta en AWS permite llevar el modelo de predicción de churn a un entorno productivo siguiendo principios de MLOps y escalabilidad. En primer lugar, los datos de clientes se almacenan en Amazon S3 como lago de datos en su estado original. El acceso a estos recursos se gestiona mediante AWS IAM, lo que garantiza control de permisos y seguridad.

En la capa de gobernanza de datos, AWS Glue Crawler identifica automáticamente los esquemas de los archivos almacenados en S3 y registra esta información en el Glue Data Catalog. Esto permite que herramientas analíticas como Amazon Athena puedan consultar los datos de forma estructurada.

Posteriormente, en la capa de procesamiento se ejecutan procesos ETL con AWS Glue, donde se realizan tareas de limpieza y transformación de datos, incluyendo el tratamiento de valores faltantes, eliminación de duplicados, estandarización de fechas y anonimización de información sensible. Los datos resultantes se almacenan nuevamente en S3 como datos procesados.

En la etapa de ingeniería de características se generan variables derivadas relevantes para el modelo, las cuales son utilizadas posteriormente para el entrenamiento del modelo de churn en Amazon SageMaker. Durante esta fase, CloudWatch permite monitorear métricas de entrenamiento y desempeño del modelo, mientras que los artefactos generados se almacenan en S3 para su gestión y versionamiento.

Una vez entrenado, el modelo se despliega mediante un endpoint de SageMaker que permite realizar inferencias en tiempo real a través de una API que recibe datos de clientes y devuelve la probabilidad de abandono.

Finalmente, las predicciones pueden almacenarse en Amazon Redshift o consultarse mediante Athena, y posteriormente visualizarse en dashboards a través de herramientas como Amazon QuickSight o Power BI. De esta manera, la arquitectura permite transformar los resultados del modelo en información accionable para la toma de decisiones en estrategias de retención de clientes.

10.2. Construcción en AWS

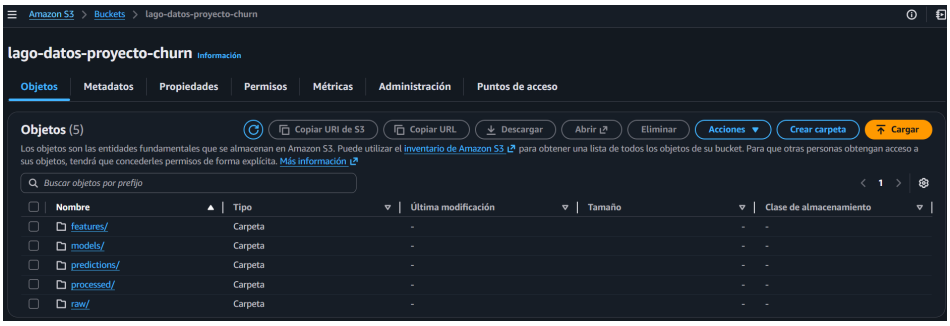

Creación y organización del Data Lake en Amazon S3

La captura muestra el bucket `lago-datos-proyecto-churn` en Amazon S3, utilizado como almacenamiento central del proyecto. La estructura del bucket está organizada siguiendo las distintas etapas del pipeline de datos:

- `raw/`: contiene los datos originales sin procesar.
- `processed/`: almacena los datos después del proceso de limpieza realizado mediante AWS Glue ETL.
- `features/`: incluye el dataset final con las variables generadas en el proceso de *feature engineering* para el modelo de churn.
- `models/`: guarda los artefactos del modelo utilizados para su despliegue en Amazon SageMaker.
- `predictions/`: carpeta destinada al almacenamiento de predicciones generadas por el modelo.

Esta organización corresponde a una arquitectura típica de *Data Lake* para proyectos de *Machine Learning*, permitiendo separar claramente cada etapa del procesamiento y modelado de los datos.

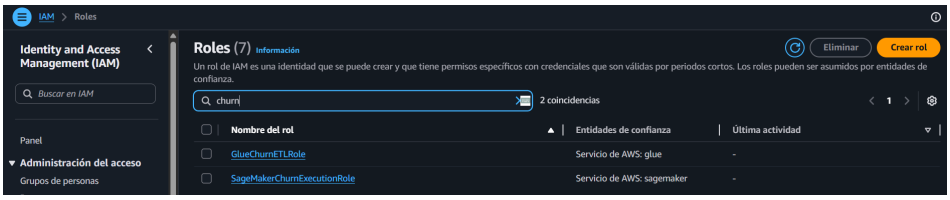

Configuración de roles en AWS IAM

La captura muestra la creación de roles en AWS Identity and Access Management (IAM) para habilitar la ejecución de los distintos servicios utilizados en el proyecto. En particular, se observan los roles `GlueChurnETLRole` y `SageMakerChurnExecutionRole`, asociados a los servicios AWS Glue y Amazon SageMaker respectivamente.

Estos roles permiten otorgar permisos controlados para acceder a recursos como Amazon S3 y ejecutar procesos de transformación de datos y despliegue de modelos, garantizando una gestión segura de credenciales dentro del pipeline de Machine Learning.

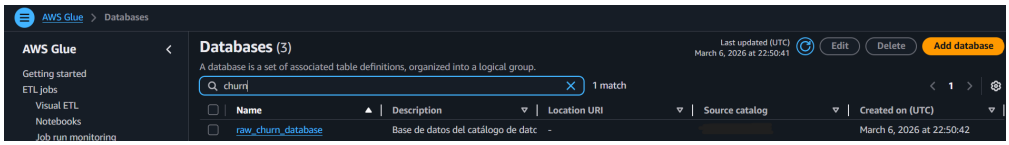

Creación de base de datos en AWS Glue Data Catalog

La captura muestra la creación de la base de datos `raw_churn_database` en AWS Glue Data Catalog. Esta base de datos permite registrar y administrar los metadatos de los datos almacenados en Amazon S3, facilitando su consulta mediante servicios como Amazon Athena y su uso en procesos ETL desarrollados con AWS Glue.

El catálogo de datos funciona como una capa de metadatos dentro del Data Lake, permitiendo organizar las tablas detectadas por los *crawlers* y estructurar los datos para su posterior procesamiento y análisis en el pipeline de Machine Learning.

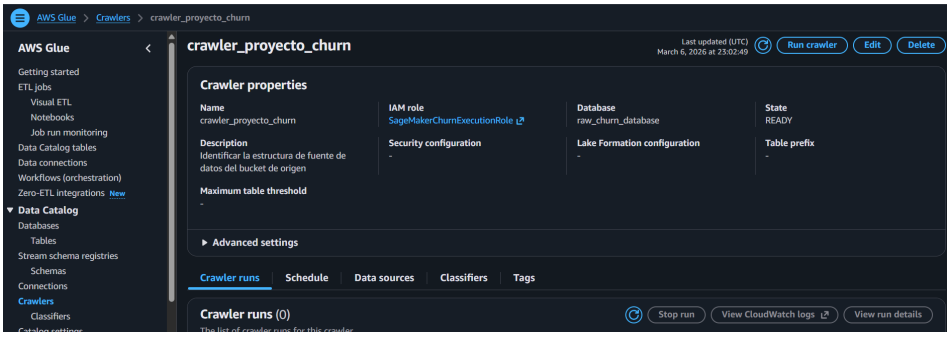

Configuración de un Crawler en AWS Glue

La captura muestra la configuración del *crawler* `crawler_proyecto_churn` en AWS Glue. Este componente permite explorar automáticamente los datos almacenados en Amazon S3 para identificar su estructura y generar tablas en el AWS Glue Data Catalog.

El *crawler* utiliza el rol de IAM `SageMakerChurnExecutionRole` para acceder a los recursos necesarios y registrar los metadatos en la base de datos `raw_churn_database`. De esta manera, los datos pueden ser posteriormente consultados mediante servicios como Amazon Athena o utilizados en procesos ETL dentro del pipeline de procesamiento de datos del proyecto.

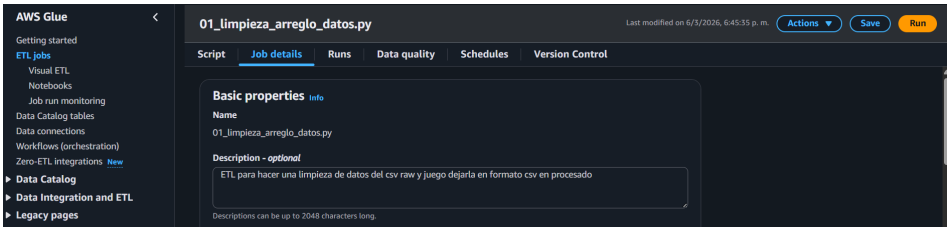

Configuración del Job ETL en AWS Glue

La captura muestra la configuración del job `01_limpieza_arreglo_datos.py` en AWS Glue, utilizado para ejecutar un proceso ETL sobre los datos almacenados en Amazon S3. Este job realiza la limpieza y transformación de la tabla *raw* que está en la base de datos `raw_churn_database` ubicada en AWS Glue Data Catalog, generando un nuevo conjunto de datos procesados que se almacena en la capa *processed* del Data Lake.

Este paso forma parte del pipeline de preparación de datos previo al proceso de *feature engineering* y entrenamiento del modelo de predicción de churn.

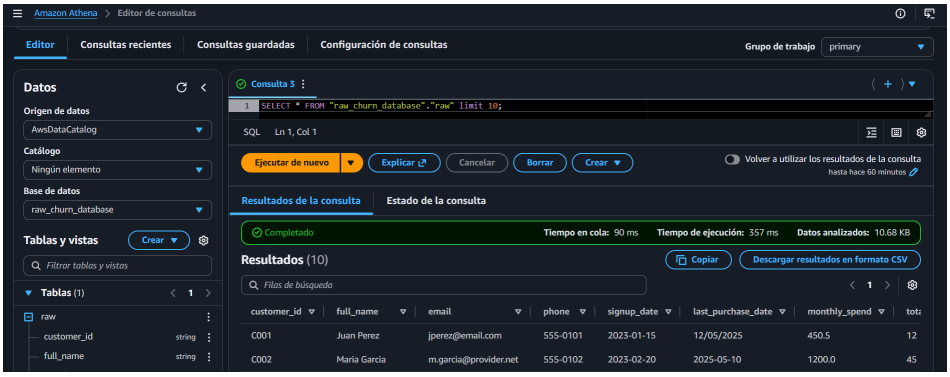

Consulta de datos mediante Amazon Athena

La captura muestra el uso de Amazon Athena para consultar los datos almacenados en el Data Lake. A través del editor de consultas se ejecuta la sentencia SQL: `SELECT * FROM raw_churn_database".Γaw"LIMIT 10;`

Esta consulta permite visualizar una muestra de los registros almacenados en la tabla `raw`, cuyos metadatos fueron previamente registrados en AWS Glue Data Catalog. Athena permite realizar consultas directamente sobre los datos almacenados en Amazon S3 sin necesidad de moverlos o cargarlos en un sistema de base de datos tradicional, facilitando la exploración y validación de los datos dentro del pipeline del proyecto.

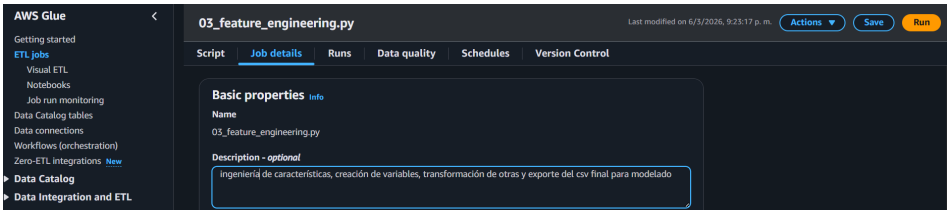

Proceso de *Feature Engineering* en AWS Glue

La captura muestra la configuración del job `03_feature_engineering.py` en AWS Glue. Este proceso ETL se encarga de realizar la ingeniería de características sobre los datos previamente limpiados, incluyendo la creación y transformación de variables relevantes para el modelado.

El resultado de este proceso es la generación de un nuevo conjunto de datos con las variables finales que serán utilizadas en el entrenamiento y despliegue del modelo de predicción de churn dentro del pipeline de Machine Learning.

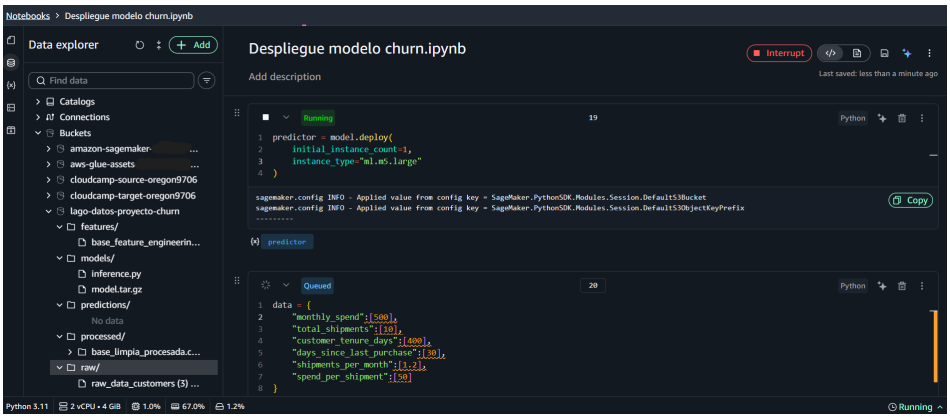

Despliegue del modelo en Amazon SageMaker

La captura muestra el proceso de despliegue del modelo de predicción de churn utilizando un notebook en Amazon SageMaker. A través del método `model.deploy()`, el modelo previamente entrenado

se publica como un *endpoint* de inferencia en tiempo real, utilizando una instancia `ml.m5.large`.

Este endpoint permite enviar nuevos datos de clientes y obtener predicciones de churn mediante llamadas a la API del modelo. De esta forma, el modelo pasa de una etapa de desarrollo a un entorno de inferencia que puede integrarse con aplicaciones o procesos analíticos dentro del pipeline de Machine Learning.

11. Consideraciones

11.1. Supuestos del modelo

Durante el desarrollo del modelo se adoptaron algunos supuestos para el tratamiento de los datos:

- Los valores faltantes en *monthly_spend* y *total_shipments* se interpretan como ausencia de actividad.
- Cuando *last_purchase_date* es nulo, se asume que la última compra coincide con la fecha de registro del cliente.

11.2. Riesgos del modelo

A pesar del buen desempeño del modelo, existen algunos factores que deben considerarse:

- El tamaño del dataset es relativamente reducido, lo que puede generar sobreajuste en algunos algoritmos.
- El comportamiento de los clientes puede cambiar en el tiempo, por lo que se recomienda realizar reentrenamientos periódicos del modelo.

11.3. Limitaciones del dataset

El conjunto de datos utilizado contiene información limitada sobre el comportamiento de los clientes. Variables adicionales como frecuencia de interacción con la plataforma, historial de soporte o información demográfica podrían mejorar la capacidad predictiva del modelo.

12. Conclusiones

El análisis exploratorio permitió identificar que variables relacionadas con la recencia de la actividad del cliente y la intensidad de uso del servicio son los principales factores asociados al churn. En particular, el tiempo desde la última compra y el número de envíos mostraron una relación significativa con la probabilidad de abandono.

En la etapa de modelado se evaluaron diversos algoritmos de clasificación, incluyendo regresión logística, Random Forest, Gradient Boosting, XGBoost, SVM y redes neuronales. Los resultados evidenciaron que los modelos basados en árboles, especialmente Random Forest y XGBoost, presentaron el mejor desempeño predictivo, alcanzando valores de ROC-AUC cercanos a 1 en validación y superiores a 0.90 en pruebas.

Asimismo, el desarrollo de variables derivadas como frecuencia de envíos y gasto por envío permitió mejorar la capacidad explicativa del modelo. Finalmente, se diseñó una arquitectura conceptual en AWS basada en S3, Glue y SageMaker que permite escalar el proceso de ingestión, procesamiento, entrenamiento y despliegue del modelo, facilitando su integración con herramientas analíticas y dashboards para apoyar la toma de decisiones estratégicas en la gestión de clientes.

13. Recomendaciones de negocio

Los resultados del modelo permiten identificar clientes con alta probabilidad de abandono, lo cual puede utilizarse para:

- Diseñar campañas de retención dirigidas a clientes con alto riesgo de churn.
- Priorizar acciones comerciales sobre clientes con menor actividad reciente.
- Optimizar estrategias de fidelización basadas en patrones de comportamiento.

14. Trabajo futuro y mejoras del modelo

Aunque el modelo presenta un buen desempeño predictivo, existen oportunidades para mejorar la solución. En primer lugar, sería conveniente incorporar nuevas variables relacionadas con el comportamiento de los clientes, como interacciones con la plataforma o historial de campañas de marketing, lo que podría mejorar la capacidad explicativa del modelo. Asimismo, el uso de un mayor volumen de datos permitiría entrenar modelos más robustos y reducir el riesgo de sobreajuste.

En un entorno productivo se recomienda implementar mecanismos de monitoreo del modelo para detectar posibles cambios en la distribución de los datos (*data drift*) o en el desempeño predictivo (*model drift*). Servicios como Amazon CloudWatch y SageMaker Model Monitor pueden utilizarse para supervisar el rendimiento del modelo, y finalmente, el pipeline podría automatizarse mediante procesos de integración y despliegue continuo, permitiendo reentrenar el modelo periódicamente a medida que se disponga de nuevos datos.